

Fisher-R1: Training LLM Agents for Reliable Hypothesis Testing

论文阅读笔记

arXiv:2608.07437, 2026

1 Motivation

p -value 依赖于所选的 statistical model，错误的 method selection 会导致错误的 conclusion。现有通用模型（如 GPT-5.4）可以可靠地查看数据、生成代码、执行分析、输出报告，但其选择的统计模型本身未必可靠；而现有 benchmark 很少评估“报告的 p -value 在数据假设下是否统计有效”，无法捕捉这一 failure mode。

论文开篇的例子 (Figure 1)：数据中存在两个 high-leverage outliers，同一份数据上 linear regression 给出 $p < 2.2 \times 10^{-16}$ ，而 Spearman rank test 给出 $p = 0.085$ 。GPT-5.4 看到了 outlier、算过 Spearman、知道 linear regression 有 warning signs，但最终仍选择 linear regression；Fisher-R1 则选择 rank test。即：

Correct execution $\neq$ valid statistical inference

2 P-Bench

2.1 测什么

每个任务的输入只有：一个描述科学问题的分析请求 + 一个 CSV 数据集，不告知模型应使用何种统计方法。模型需要独立完成完整链条：

question $\rightarrow$ data exploration $\rightarrow$ method selection $\rightarrow$ execute R $\rightarrow$ p -value $\rightarrow$ decision.

这与 StatQA 一类选择题 benchmark 的核心区别是：不是从选项中挑方法，而是 end-to-end 的自主决策与执行，且同时评估 p -value 与 conclusion 的统计有效性。

2.2 构造与 ground truth

共 203 Easy + 222 Hard = 425 个任务，来自经济学、生物学、医学领域的真实论文及其数据集，覆盖 17 类 hypothesis-testing methods (t -test、 χ^2 、OLS、Fisher exact，以及 Cox PH、IV/2SLS、mixed effects、Tobit 等)。Hard 子集包含 statistical traps: model specification、assumption checking、outliers、heteroskedasticity、clustered observations 等。

答案不是从论文文本里抽一个 p -value，而是来自 canonical analysis 的真实执行：

paper + dataset + analysis code $\rightarrow$ 重新运行 $\rightarrow$ execution log $\rightarrow$ 提取 p^* 与 conclusion $\rightarrow$ 专家审查
即 keys 由 canonical reference code 计算并经专家检查，可执行、可复现。

3 Fisher-R1

方法主线：

Synthetic executable tasks $\rightarrow$ expert SFT warm start $\rightarrow$ outcome-verifiable RL.

3.1 六维合成任务空间

合成任务来自六维 task taxonomy：

$$M \times S_m \times N \times E \times P \times K$$

维度	含义
M	statistical method
S_m	scenario（应用场景）
N	sample size
E	effect size（null / borderline / medium）
P	prompt style（hint / non-hint）
K	random seed

训练空间包括 27 种 statistical methods、每种 5-7 个场景、多种 N 与 effect size、hint/non-hint prompt，共合成 8642 个任务。每个坐标点产生一个可执行的统计任务，DGP 生成 dataset.csv，同时用 canonical method 运行得到 p^* ，因此天然具有 machine-verifiable 的 answer key。

3.2 SFT warm start

- Teacher 模型为 Claude Sonnet 4.6，按固定五步 workflow 生成轨迹：

EDA $\rightarrow$ detailed EDA $\rightarrow$ assumption checking $\rightarrow$ method selection $\rightarrow$ conclusion;

- 共生成 4611 条 trajectory，筛选后保留 3851 条，格式化为 ReAct / CodeAct 格式，作为 Qwen（7B / 14B）的 SFT warm-start。

3.3 Outcome-verifiable RL

因为 synthetic task 自带 verifiable ground truth p^* , 可以定义 reward (论文原式):

$$R(o) = I_{\text{valid}}(o) [w_p r_p(o) + w_c r_c(o)], \quad w_p = 0.9, \quad w_c = 0.1.$$

p-value accuracy (权重 90%)。 先做 z 变换再比较:

$$z(p) = \Phi^{-1}\left(1 - \frac{p}{2}\right), \quad r_p(o) = \exp\left(-\frac{|\min\{z(\hat{p}), 5\} - \min\{z(p^*), 5\}|}{\sigma}\right).$$

不用 raw p -difference 的原因: $0.5 \leftrightarrow 0.6$ 与 $0.1 \leftrightarrow 10^{-10}$ 的 $|\Delta p|$ 可能接近, 但代表的 statistical evidence 差距完全不同。

Conclusion accuracy (权重 10%)。 判断模型给出的 reject / fail-to-reject 决策是否正确。

优化算法: DAPO。

$$\hat{A}_i = \frac{R_i - \mu}{\sigma + \epsilon}$$

即同一道题的多个 rollout 之间的相对质量: positive advantage 提高概率, negative advantage 降低概率, clip 保证单步更新不过于激进。训练时丢弃 $\sigma_q^2 = 0$ 的 group (同组所有 rollout 的 reward 没有差异, 不存在 relative advantage learning signal)。

4 实验结果

Post-training 提升巨大。 7B backbone 在 Hard Strict pass@1 上从 13.2% 提升到 30.6%。

14B 部分超越 GPT-5.4。 Fisher-R1-14B 在四个 Strict metric 中的三个超过 GPT-5.4, 例如 Hard: 33.0% vs. 30.5%。

Raw vs. Strict gap。 GPT-5.4 在 Hard pass@1 上 Raw = 58.3%, 但 Strict = 30.5%。这说明模型经常能得到正确的显著方向, 但无法可靠地产生正确的 statistical evidence, 即 conclusion accuracy 会明显高估统计可靠性。

5 Ablation 与 Generalization

P-Hard Strict pass@1 (%):

设置	pass@1
Backbone only	13.2
+ DAPO only	25.2
+ SFT only	14.3
SFT + DAPO	30.6

SFT warm-start 与 outcome RL 是互补的。另外，训练任务全部是 synthetic 而 P-Bench 任务来自真实论文；embedding nearest-neighbor 分析未发现 P-Bench 任务与训练 prompt 存在 near-duplicate。

6 Limitations

- 目前只评估单个 hypothesis test，未覆盖 multiple-testing / 多阶段分析 workflow；
- method choice 存在 uncertainty：同一问题常有多个 defensible 的 statistical procedures，reward 因此不直接奖励 method correctness，而是以逼近 canonical p^* 为目标——即 Fisher-R1 学到的是“产生接近专家 canonical analysis 的推断”，而非“找到唯一正确的统计方法”；
- 有的问题可能根本不存在单一的、可靠的假设检验方法。

7 Takeaway

1. Executable analysis does not imply valid inference.
2. P-Bench 用可执行、专家级 ground truth 的真实任务暴露并量化了这一 gap。
3. Synthetic verifiable post-training (SFT + outcome RL) 可以大幅提升统计推断的可靠性。