

Fisher-R1: Training LLM Agents for Reliable Hypothesis Testing

可执行的分析 $\neq$ 可靠的统计推断

汇报人

2026 年 8 月

Outline

- 1 Motivation: 现有 LLM Agent 的失败模式
- 2 P-Bench (一): 它到底测什么
- 3 P-Bench (二): 构造与 Ground Truth 的可信性
- 4 Fisher-R1 (一): 六维 Synthetic Task Space
- 5 Fisher-R1 (二): SFT Warm Start
- 6 Fisher-R1 (三): Outcome-Verifiable RL
- 7 实验结果
- 8 Limitations 与个人讨论
- 9 Takeaway

Opening: 一张图看懂全文 (Figure 1 的故事)

场景: 数据中存在两个 **high-leverage outliers**, 同样的数据:

- Linear regression 给出 $p < 2.2 \times 10^{-16}$ (极显著)
- Spearman rank test 给出 $p = 0.085$ (不显著)

GPT-5.4 的表现:

- 看到了 outlier
- 算过 Spearman
- 知道 linear regression 有 warning signs
- **最终仍然选择 linear regression**

Fisher-R1: 最终选择 rank test。

Correct execution $\neq$ valid statistical inference

为什么需要专门的 Benchmark?

- p -value 依赖于所选的 statistical model; 错误的 method selection 导致错误的 conclusion。
- 现有通用模型 (GPT-5.4 等) 可以可靠地看数据、生成代码、执行分析、输出报告——**但所选统计模型本身未必可靠。**
- 现有 benchmark 很少评估“报告的 p -value 在数据假设下是否统计有效”，无法捕捉这一 failure mode。

汇报重点排序: Motivation > P-Bench $\approx$ Synthetic Verifiable Training > Experimental Findings > Fisher Reward > DAPO Details

P-Bench 评测的完整链条

输入：一个科学问题的分析请求 + 一个 CSV 数据集。 **不告知模型应使用何种统计方法。**

模型需要独立完成完整链条：

question → data exploration → method selection → execute R → p -value → decision

与 StatQA 类选择题 benchmark 的核心区别：

- 不是从选项中挑方法，而是 end-to-end 自主决策 + 执行；
- 评的不只是“方法选对没”，还有 p -value 与 conclusion 的统计有效性。

425 个任务从哪里来？

$$203 \text{ Easy} + 222 \text{ Hard} = \boxed{425}$$

- 来自经济学、生物学、医学领域的**真实论文**及其数据集；
- 覆盖 **17 类**实际使用的 hypothesis-testing methods:
 - 常规方法: t -test、 χ^2 、OLS、Fisher exact 等
 - 高级方法: Cox PH、IV/2SLS、mixed effects、Tobit 等
- Hard 不仅是“题目更复杂”，而是包含 statistical traps: model specification、assumption checking、outliers、heteroskedasticity、clustered observations。

Ground truth 为什么可信? (关键一页)

答案不是从论文文本里抽一个 p -value, 而是来自 **canonical analysis 的真实执行**:

paper + dataset + analysis code $\rightarrow$ 重新运行 $\rightarrow$ execution log $\rightarrow$ 提取 p^* , conclusion $\rightarrow$ 专

- Keys 由 canonical reference code 计算得到, 并经专家检查。
- 应对质疑: “你说 GPT-5.4 错, 凭什么 benchmark 的答案是对的?” ——因为答案是**可执行、可复现的 canonical 代码**算出来的, 而非模型或人工的主观判断。

Task Taxonomy: 合成任务不是乱生成的

$$M \times S_m \times N \times E \times P \times K$$

维度	含义
M	statistical method
S_m	scenario (应用场景)
N	sample size
E	effect size (null / borderline / medium)
P	prompt style (hint / non-hint)
K	random seed

附录训练空间: **27 种** statistical methods、每种 5-7 个场景、多种 N 与 effect size、hint/non-hint prompt, 共合成 **8642** 个任务。

为什么 Synthetic 让 RL 成为可能

每一个坐标点产生一个**可执行**的统计任务，自然得到 machine-verifiable answer key:

$$\text{DGP} \rightarrow \text{dataset.csv} \quad \text{dataset} \xrightarrow{\text{canonical method}} p^*$$

核心创新不是“我们用了 DAPO 训练 Qwen”，而是
把一个难以自动监督的统计推断问题，转化为可自动生成 ground truth、可自动计算 reward、进而可做 RL 的任务。

方法主线压缩为：

Synthetic executable tasks $\rightarrow$ expert SFT warm start $\rightarrow$ outcome-verifiable RL

SFT: 轻量带过

- Teacher: Claude Sonnet 4.6;
- 固定**五步 workflow**生成轨迹:

EDA → detailed EDA → assumption checking → method selection → conclusion

- 共生成 4611 条 trajectory, 筛选后保留 3851 条;
- 格式化为 ReAct / CodeAct 格式;
- 作为 Qwen (7B / 14B) 的 SFT warm-start。

备注 (若被问 *SFT loss*): prompt / observation 只作为 context, 只有 assistant tokens 计算 loss。

Fisher Reward (重点)

先回答：**为什么这里能做 RL?** ——因为 synthetic task 自带 verifiable ground truth p^* 。于是定义 (论文原式)：

$$R(o) = I_{\text{valid}}(o) [w_p r_p(o) + w_c r_c(o)], \quad w_p = 0.9, \quad w_c = 0.1$$

90%: p -value accuracy. 先做 z 变换再比较：

$$z(p) = \Phi^{-1}\left(1 - \frac{p}{2}\right), \quad r_p(o) = \exp\left(-\frac{|\min\{z(\hat{p}), 5\} - \min\{z(p^*), 5\}|}{\sigma}\right)$$

为什么不用 raw p -difference? $0.5 \leftrightarrow 0.6$ 与 $0.1 \leftrightarrow 10^{-10}$ 的 $|\Delta p|$ 可能接近, 但 statistical evidence 的差距完全不同。

10%: conclusion accuracy. 判断 reject / fail-to-reject 是否正确。

DAPO: 两分钟讲完

They optimize this reward using **DAPO**, a group-relative policy optimization method:

$$\hat{A}_i = \frac{R_i - \mu}{\sigma + \epsilon}$$

- $\hat{A}_i$ 代表**同一道题**多个 rollout 中的相对质量;
- positive advantage $\uparrow$ probability, negative advantage $\downarrow$ probability;
- clip 保证单步更新不要过于激进;
- 丢弃 $\sigma_q^2 = 0$ 的 group——即同组所有 rollout 的 reward **没有差异** (可能全 0、全 1 或全部相同值), 目的是丢掉**没有** relative advantage learning signal 的组, 而非专门丢弃失败组。

Main Results (Table 1): 只挑三个事实

事实 1: post-training 提升巨大

7B backbone: 13.2% $\rightarrow$ 30.6% (Hard Strict pass@1)

事实 2: 14B 部分超越 GPT-5.4

Fisher-R1-14B 在四个 Strict metric 中三个超过 GPT-5.4, 例如 Hard:

33.0% vs. 30.5%

(注意分寸: 不是做成 ‘我们打赢了 *GPT-5.4*’ 的叙事。)

事实 3: Raw vs. Strict gap (最具科学意义)

GPT-5.4 Hard pass@1: Raw = 58.3%, Strict = 30.5%

直接支持论文 thesis: 模型常能得到正确的显著方向, 但无法可靠地产生正确的 statistical evidence。

Conclusion accuracy can substantially overestimate statistical reliability.

- Raw (结论方向对) $\neq$ Strict (p -value 与方法也对);
- 这正是 Figure 1 失败模式的定量版本：执行正确、结论方向碰对，但 statistical evidence 无效；
- 也因此 P-Bench 的 Strict 评价才是这篇工作真正的贡献点。

Ablation (P-Hard Strict pass@1, %):

设置	pass@1
Backbone only	13.2
+ DAPO only	25.2
+ SFT only	14.3
SFT + DAPO	30.6

SFT warm-start 与 outcome RL 是互补的。

Generalization: 训练任务全是 synthetic、P-Bench 任务是真实的；作者做了 embedding nearest-neighbor 分析，未发现 P-Bench 任务与训练 prompt 存在 near-duplicate。

- 目前只评估**单个** hypothesis test;
- 未覆盖 multiple-testing / 多阶段分析 pipeline;
- method choice 存在 uncertainty: 同一问题常有多个 defensible statistical procedures;
- 有的问题可能根本不存在单一的 adequate test。

我的 Critique: Method 非唯一 vs. Reward 指向唯一

作者一方面承认**多个 statistical procedures 都可能 defensible**, 因此 reward 不直接奖励 method correctness; 另一方面又通过逼近某个 canonical p^* 来评价模型。于是存在 tension:

method may be non-unique

but

reward target is essentially one canonical inference

因此 Fisher-R1 更准确的定性是学习:

produce inference close to an expert canonical analysis

而不能等价为:

discover the uniquely correct statistical method.

- ① Executable analysis does not imply valid inference.
- ② P-Bench 用可执行、专家级 ground truth 的真实任务，暴露并量化了这一 gap。
- ③ **Synthetic verifiable post-training** (SFT + outcome RL) 可以大幅提升统计推断的可靠性。

Reference: Miao, Mu, Chen & Zou. Fisher-R1: Training LLM Agents for Reliable Hypothesis Testing. arXiv:2608.07437, 2026.

Thanks!

Q & A